

تشخیص گفتار فارسی به متن — خلاصه بنچمارک

مقایسه مدل‌های متن‌باز و قابل‌اجرای محلی تبدیل گفتار فارسی به متن برای یک محصول STT بالینی (گفت‌وگوی پزشک-بیمار). تصمیم بر دو شرط استوار است — گفتار تمیز و یک مجموعه نویز بالینی واقع‌گرایانه؛ سه شرط دیگر برای زمینه آزمایش شدند و در پایان به اختصار خلاصه می‌شوند.

مجموعه‌های داده

دو موردی که اهمیت دارند

۱. **FLEURS fa_ir — تمیز (خط پایه).** بخش آزمون فارسی FLEURS گوگل: ۸۷۱ کلیپ، حدود ۲.۷ ساعت، 16 kHz مونو، خوانش متن ادبی فارسی توسط گویندگان بومی در شرایط کنترل‌شده (تقریباً تمیز). آهنگ خنثی، بدون اختلال‌های گفتار خودجوش. سقف دقت هر مدل را می‌سنجد و مرجعی است که مجموعه نویزی کلیپ‌به‌کلیپ با آن مقایسه می‌شود.

۲. **نویز بالینی واقع‌گرایانه (fleurs_noisy_real) — مجموعه تصمیم.** برگرفته از ۲۰۰ FLEURS: کلیپ پایه $5 \times$ سطح نویز = ۱۰۰۰ کلیپ (حدود ۴.۴ ساعت)، هر کلیپ از زنجیره افتی می‌گذرد که میکروفون ضعیف در یک اتاق بالینی کوچک را شبیه‌سازی می‌کند:

مرحله	اثر	شبیه‌سازی
۱	طنین اتاق (اتاق کاشی‌کاری کوچک، RT60 $\approx$ 0.45 ثانیه)	پژواک اتاق
۲	کف نویز گاوسی (به SNR هدف مقیاس می‌شود)	نویز خودی الکترونیکی میکروفون ارزان
۳	باند-محدودسازی (120–6000 هرتز)	افت فرکانسی میکروفون ارزان
۴	کلیپینگ ملایم (drive 0.15)	میکروفون اشباع‌شده / نزدیک‌به‌دهان
۵	رفت‌وبرگشت کدک Opus با ۲۰ kbps	فشرده‌سازی VoIP / ضبط ارزان

طنین و مراحل میکروفون/کدک با قدرت ثابت اعمال می‌شوند؛ فقط **کف گاوسی** در طول **چاروب SNR برابر 0 / 5 / 10 / 15 / 20 dB** تغییر می‌کند (۲۰۰ کلیپ در هر سطح). dB بالاتر = تمیزتر؛ **20 dB** ≈ خفیف، **10 dB** ≈ آشکارا نویزی، **0 dB** ≈ نویز هم‌اندازه گفتار. (کف نویز گاوسی مصنوعی است — نه همهمه/سرفه/تهویه ضبط‌شده — پس پروفایل، افت میکروفون + اتاق + کدک را مدل می‌کند. یک پروفایل بدترین حالتِ شدیدتر وجود دارد اما اجرا نشد.)

معیارها، به اختصار

WER/CER = نرخ خطای کلمه/کاراکتر (کمتر بهتر). **ΔWER** = افت تمیز→نویزی روی همان کلیپ‌ها (کمتر = مقاوم‌تر). **%فاجعه‌بار** = کلیپ‌هایی با $WER > 0.5$ (عمدتاً غیرقابل استفاده). **%توهم** = کلیپ‌هایی با جعل با اطمینان (معیار کلیدی ایمنی پزشکی). **بازه اطمینان ۹۵%** = بازه بوت‌استرپ روی WER (عدم هم‌پوشانی = تفاوت واقعی). **جایگزینی/درج/حذف** = نوع خطا — درج ≈ جعل، حذف ≈ گفتار افتاده. **VRAM/RTF** = حافظه GPU و سرعت ($RTF < 1$ = سریع‌تر از زمان واقعی).

نتایج — تمیز در برابر نویز بالینی واقع‌گرایانه (N: تمیز ۸۷٪، بالینی ۱۰۰٪)

مرتب‌شده بر اساس WER نویز بالینی.

#	مدل	WER تمیز	WER بالینی	ΔWER	بازه اطمینان ۹۵٪ بالینی	%فاجعه‌بار	%توهم
۱	seamless-m4t-v2-large	0.107	0.315	0.207+	[0.34–0.29]	0.18	0.012
۲	whisper-persian-v4 (nezamisa)	0.137	0.484	0.348+	[0.51–0.46]	0.41	0.004
۳	hf-seamless-m4t-medium	0.134	0.495	0.361+	[0.54–0.46]	0.31	0.046
۴	persian-whisper-large-v3 (Halakoo)	0.191	0.601	0.410+	[0.64–0.58]	0.57	0.006
۵	mms-1b-all	0.162	0.610	0.448+	[0.63–0.60]	0.63	0.000
۶	mms-1b-fl102  درون‌حوزه‌ای	0.146	0.623	0.477+	[0.64–0.61]	0.62	0.000
۷	vhdm/whisper-large-fa-v1	0.150	0.638	0.488+	[0.70–0.59]	0.52	0.029
۸	wav2vec2-large-xlsr-53	0.240	0.676	0.436+	[0.69–0.67]	0.77	0.000

#	مدل	WER تمیز	WER بالینی	Δ WER	بازۀ اطمینان ۹۵٪ بالینی	% فاجعه بار	% توهّم
۹	openai/whisper-large-v3	0.198	0.716	0.518+	[0.80–0.67]	0.54	0.035
۱۰	openai/whisper-large-v3-turbo	0.204	1.088	0.883+	[1.22–1.01]	0.60	0.114

یافته‌ها

۱. seamless-m4t-v2-large در هر دو شرط برنده است — قاطعانه زیر نویز. رتبهٔ اول تمیز (0.107) و رتبهٔ اول بالینی (0.315) — با فاصلهٔ ۰.۱۷ WER از نفر دوم و بازۀ اطمینان غیرهم‌پوشان روی (N=1000)، با **کمترین افت** (Δ WER +0.207)، **کمترین نرخ فاجعه بار** (۱۸٪)، بهترین CER (0.178) و توهّم پایین (۱.۲٪). پایهٔ ساخت سیستم بالینی است (حدود ۱۱ تا ۱۵ GB حافظه، حدود ۸ برابر زمان واقعی).

۲. رتبه‌بندی زیر نویز جابه‌جا می‌شود، با محرک مقاومت در برابر توهّم. فاین‌تیون‌های فارسی‌ای که جعل نمی‌کنند بالا می‌آیند (nezamisafa، Halakoo)؛ آن‌هایی که جعل می‌کنند فرو می‌پاشند (vhdm، turbo، large-v3). دقت تمیز به‌تنهایی عملکرد بالینی را پیش‌بینی نمی‌کند.

۳. نوع خطا داستان ایمنی است. زیر نویز، seamless-v2 تقریباً فقط با جایگزینی خطا می‌کند (درج/حذف پایین) — نوع قابل‌بازبایی. turbo با جعل فرو می‌پاشد ($WER >$ ۱۱٪، 1.0 توهّم)، و whisper-large-v3 به‌محض رسیدن مرحلهٔ میکروفون/کدک توهّم می‌زند. مدل‌های CTC (mms-1b-a11، wav2vec2) هرگز جعل نمی‌کنند اما گفتار را می‌اندازند و امتیاز ضعیفی دارند ($WER \geq 0.61$) — مرجع «شکست ایمن»، نه موتور اصلی.

۴. گزینهٔ سبک ردهٔ دوم: (nezamisafa) whisper-persian-v4 — رتبهٔ دوم زیر نویز، کمترین توهّم میدان (۰.۴٪)، روی تنها 3.4 GB حافظه. گزینهٔ مقرون‌به‌صرفه وقتی حجم Seamless زیاد است (افت دقت حدود ۰.۱۷ WER).

۵. برای کاربرد بالینی کنار گذاشته شوند: turbo و v1-whdm/whisper-large-fa — هر دو زیر نویز توهّم می‌زنند، و جعل با اطمینان (ساختن نام دارو، حذف یک نفی) برای کاربرد پزشکی صرف‌نظر از دقت تمیز مردود است.

هشدارها

- به‌صورت خام آمادهٔ تولید نیست. حتی برنده روی ۱۸٪ / 0.315 WER فاجعه بار قرار دارد. یک سیستم قابل‌استقرار به فاین‌تیون حوزه‌ای + پس‌اصلاح با LLM (مثلاً Dorna2 از PartAI) + بازیابی انسانی مبتنی بر اطمینان روی STT پایه نیاز دارد.
- فقط صدای سالم. مجموعهٔ بالینی محیط را بازتولید می‌کند (طنین، میکروفون ارزان، کدک — اعتبارسنجی‌شده با گوش) اما از گویندگان سالم FLEURS استفاده

می‌کند، پس گفتار بیمار مضطرب/آسیب‌دیده را در بر نمی‌گیرد. این شکاف برای اعتبارسنجی نهایی به داده بالینی واقعی نیاز دارد.

سایر شرایط آزمون‌شده (به اختصار)

- **PSRB (PartAI) — فارسی نویزی و خودجوش واقعی.** میدان را جابه‌جا کرد و whisper-large-v3 را در صدر نشانده، اما محتوای آن عمدتاً گفت‌وگوی نمایشی **تلویزیون/فیلم** (لحن اغراق‌شده) است، پس نماینده ضعیفی برای لحن گفتار بالینی است — به عنوان زمینه استفاده شد، نه مجموعه تصمیم.
 - **Common Voice fa — گفتار خوانشی واقعی.** برای چند مدل آسان‌تر از FLEURS تمیز بود؛ عملاً یک مجموعه تمیز دوم، نه آزمون نویز.
 - **گاوسی مصنوعی خالص (جاروب SNR).** نویز افزایشی خالص روی گفتار خوانشی تمیز، رتبه‌بندی تمیز را تقریباً عیناً حفظ کرد (همبستگی اسپیرمن ≈ 1.0). پس سیگنال کمی برای انتخاب مدل داد — فقط شیب افت و پرتگاه نویز CTC را آشکار کرد. به همین دلیل زنجیره واقع‌گرایانه (طنین + میکروفون + کدک)، نه گاوسی ساده، بنچمارک معنادار بالینی است.
-

فقط مدل‌های متن‌باز و قابل اجرای محلی؛ تمام استنتاج‌ها با دقت FP16 روی یک GPU مدل NVIDIA T4 (در Kaggle). متن فارسی با Hazm نرمال‌سازی شد؛ معیارها با jiwer، sacrebleu، bert-score و sentence-transformers محاسبه شدند.